Introducción a R Sesión 2: Elementos de Programación con R

Jorge de la Vega Góngora

Instituto Tecnológico Autónomo de México

Sábado 28 de enero de 2023



JVG (ITAM) CursoR 21/01/23 1/39

- Estructuras de datos
 - Tipos de objetos en R
 - Vectores
 - Matrices
 - Arreglos
 - Listas
 - Tipos de listas: Dataframes
 - Formas de Indexación



JVG (ITAM) CursoR 21/01/23 2/39

Estructuras de datos

Descripción concisa de objetos en R

En esta sección se describirán los principales tipos de objetos que se usan comunmente en R. Estos son:

- Vectores
- Matrices
- Arreglos
- Listas
- Factores
- Dataframes
- Funciones
- Indexación

A continuación veremos las características de cada uno de estos tipos de objetos.

Vectores I

Un vector es un conjunto ordenado de datos que son **del mismo tipo base o clase** (no se pueden mezclar). Cada elemento de un vector se le llama componente. Las clases pueden ser:

numéricos numeric. Estos pueden ser a su vez de subclases: integer o double o complex

```
(x <- c(2,4,6))
[1] 2 4 6
class(x)
[1] "numeric"
1:5 #El símbolo ":" es para indicar una sucesión
[1] 1 2 3 4 5
```

lógicos logical

```
(1 <- c(TRUE,FALSE,TRUE,TRUE,FALSE))

[1] TRUE FALSE TRUE TRUE TRUE FALSE

class(1)

[1] "logical"

class(1) <- "integer" #Podemos cambiar la clase para representar los valores lógicos como 0's y 1's

1

[1] 1 0 1 1 0

class(1) <- "logical" # y podemos regresarlos a su clase original.

1

[1] TRUE FALSE TRUE TRUE FALSE
```

Vectores II

caractéres character

```
(a <- c("a","b",'c')) #Se pueden usar comillas dobles o sencillas, pero tienen que ser consistentes.
[1] "a" "b" "c"
(b <- c('a','b',"c"))
[1] "a" "b" "c"
class(b)
[1] "character"</pre>
```

Consideremos algunas propiedades y operaciones con los vectores.

 Cada componente de un vector se le puede asignar un nombre. El nombre es un atributo del vector.

 Otro atributo del vector es su longitud (length): es decir, el número de elementos que tiene el vector

 Los vectores se pueden combinar. Cuando los vectores no son del mismo tipo, R cambia el tipo base al más general posible: esto se llama coerción. Esto es necesario para mantener el mismo tipo de datos.

Uso de índices para accesar componentes del vector

```
x[2] #podemos tomar un elemento
[1] 2
x[1:3] # o un subconjunto del vector.
[1] 1 2 3
x[10] # cuando se usa un indice que no es parte del vector
[1] NA
x[c(1,1,3)] #los indices se pueden duplicar
[1] 1 1 3
```

o por nombre si lo tiene:

```
x["rojo"]
[1] NA
```

Para quitar elementos usamos un signo negativo:

Otras formas de crear vectores:

```
z <- numeric(10) # crea un vector de longitud 10, numérico. No tiene valores.

[1] 0 0 0 0 0 0 0 0 0 0 0 0

z <- character(10)

z

[1] "" "" "" "" "" "" "" "" "" "" ""

z <- logical(10)

z

[1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE

z <- numeric(0) # define un vector sin elementos (vacío) es mejor que z <- NULL. Es mejor definir los objetos del tamaño final que teno z

numeric(0)
```

Ejemplo I

En ocasiones se puede hacer un vector vacío de longitud conocida. El propósito es hacer una 'reserva de memoria' de la computadora cuando estamos programando, y construímos el siguiente ejemplo para aprovechar el momento e introducir el concepto de ciclo for en un programa.

Ejercicio

Supongan que quieren distribuir a un número de estudiantes dado los problemas de una tarea al azar.

Para el ejercicio necesitamos extraer tantos números como estudiantes tenemos.

• Las operaciones aritméticas de los vectores se llevan componente a componente:

```
x <- c(1,4,5,2,10)
y <- c(3,1,2,5,6)
x + y
[1] 4 5 7 7 16
x - y
[1] -2 3 3 -3 4
x * y
[1] 3 4 10 10 60
x/y
[1] 0.3333333 4.0000000 2.5000000 0.4000000 1.6666667
```

 Si un vector se divide o multiplica por un número, cada componente del vector se multiplica/divide por ese número. Si un número se divide por un vector, se obtiene un vector el número dividido por cada componente

```
W <- 1:5

2*W

[1] 2 4 6 8 10

2/W

[1] 2.0000000 1.0000000 0.6666667 0.5000000 0.4000000
```

• Regla del reciclaje: ¿Qué pasa si intentamos hacer operaciones con vectores que tienen diferente longitud? Resulta la siguiente regla:

El vector más corto se reciclará para que tenga el tamaño del vector más grande

```
u <- c(10,20,30)
v <- 1:9
u + v
[1] 11 22 33 14 25 36 17 28 39
```

Hay que tener esta regla presente y tener mucho cuidado al usarla o no darse cuenta de que se está aplicando.

Un tipo especial de vector: los factores I

Factores

- Los objetos llamados factores son un tipo especial de vector que típicamente se utilizan para guardar variables que clasifican cosas. Estas variables tienen un significado especial en estadística, particularmente en el análisis de regresión y en el diseño de encuestas, como veremos más adelante en el diplomado.
- La característica importante de un factor es que etiquetan observaciones a pertenecer a cierto grupo o categoría. Por ejemplo, la religión, el sexo, el estado civil, el estado de la república, etc, son ejemplos de variables que pueden considerarse factores cuando se usan para separar grupos.
- Los niveles o etiquetas de los grupos no son relevante en sí, sólo el hecho de que distinguen a las observaciones en diferentes grupos. Se puede usar 'H' y 'M' o bien 0 y 1 o bien 1 y 0, para distinguir las observaciones de hombres y de mujeres.

Un tipo especial de vector: los factores II

```
# variable con los tipos de crédito: hip = hipotecario, TC = tarjeta de crédito, per = personal.
credito <- factor(c("hip", "TC", "per", "hip", "per", "TC", "TC"))
credito
[1] hip TC per per hip per TC TC
Levels: hip per TC</pre>
```

En un factor, R ordena Los niveles alfabéticamente. Algunas funciones le dan un valor especial al primer nivel, por lo que a veces se requiere dar explícitamente los niveles.

En ciertos casos, los grupos pueden tener tener un orden, por ejemplo, si se considera ingreso, se puede pensar en un ingreso bajo, medio o alto. En ese caso se dice que el factor es *ordinal*. Cuando los factores son ordinales, se puede indicar el orden deseado de las etiquetas:

```
ingreso <- ordered(c("M","B","M","A","M","B","B","A"), levels = c("B","M","A"))
ingreso
[1] M B M A M B B A
Levels: B < M < A</pre>
```

Una variable que es continua pero que se quiere separar en rangos para definir grupos (por ejemplo, el ingreso bajo puede ir de 0 a 1000 mensuales), se puede *discretizar* usando la función cut:

```
z \leftarrow rnorm(20)
 [1] -1.77741250 0.40500014 -0.29729550 -1.43925049 0.62705810 0.31480323
     0.99574912 2.58152671 1.10064035 -0.92451097 -0.74233618 2.42701236
[19] 0.06900982 -1.38243553
u \leftarrow cut(z,breaks = c(-4,-2,0,2,4)) #damos los puntos de corte
u <- ordered(u, levels(u))
 [1] (-2,0]
          (0,2]
                 (-2.0] (-2.0] (0.2] (0.2] (0.2]
                                                             (0,2]
           (-2.0] (-4.-2] (0.2] (2.4] (0.2] (-2.0] (-2.0] (2.4]
[10] (0.2]
[19] (0.2]
           (-2.0]
Levels: (-4,-2] < (-2,0] < (0,2] < (2,4]
levels(u) <- c("B", "MB", "MA", "A") #Podemos reetiquetar los niveles para hacerlos más fáciles de leer o entender
```

Matrices I

Matrices

Una *matriz* es un conjunto de datos arreglados en un rectángulo en dos dimensiones (tiene renglones y columnas). Por ejemplo, la siguiente matriz tiene dos renglones y tres columnas:

$$\mathbf{A} = \begin{bmatrix} 2 & 4 & 3 \\ 1 & 5 & 7 \end{bmatrix}$$

También se puede pensar en una matriz como un vector con atributo de dimensión (dim). Entonces, de hecho, las matrices en R son también vectores.

Veamos unos ejemplos:

```
x <- 1:20 x

[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20

dim(x) <- c(2,10) #le asignamos dimensión al vector x

x

[,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10]
[1,] 1 3 5 7 9 11 13 15 17 19
[2,] 2 4 6 8 10 12 14 16 18 20

dim(x) <- NULL #¿qué pasa si le quitamos su dimensión? También se puede usar c(x)

x

[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
```

Para crear una matiz, se puede usar la siguiente forma

La matriz también se puede llenar por renglones usando índices para sus componentes

Los elementos de la matriz se pueden accesar usando:

Matrices IV

```
A[2,3] # El elemento en el renglón 2 y columna 3

[1] 6

A[2,] # Todo el renglón 2, notar que es un vector

[1] 4 5 6 2 1

A[,3] # Toda la columna 3, notar que es un vector

[1] 6 6

A[,c(1,3)] # Columnas 1 y 3, es una sub-matriz

[,1] [,2]

[1,] 2 6
[2,] 4 6
```

El número de renglones y columnas pueden obtenerse con las funciones nrow y ncol.

```
nrow(A)
[1] 2
ncol(A)
[1] 5
```

Podemos asignar nombres a los renglones y a las columnas de la matriz, y como en el caso de los vectores, podemos accesar a los elementos por los nombres:

Operaciones con matrices I

La transpuesta de una matriz intercambia los renglones y columnas. La notación matemática de la transpuesta de una matriz A es A^T o A' o A^t .

```
# No es necesario dar el número de columnas cuando tenemos la longitud
# y el número de renglones:

B <- matrix(1:6,nrow=3)
B

[,1] [,2]
[1,] 1 4
[2,] 2 5
[3,] 3 6

t(B) # transpuesta de B

[,1] [,2] [,3]
[1,] 1 2 3
[2,] 4 5 6
```

Así como con los vectores, si multiplicamos dos matrices que tengan las mismas dimensiones, la multiplicación se hace entrada a entrada:

Operaciones con matrices II

```
B*B

[,1] [,2]
[1,] 1 16
[2,] 4 25
[3,] 9 36
```

Pero ese tipo de producto no es el *producto de matrices* que se utiliza en matemáticas. El producto matricial tiene una notación especial: %*%s y sólo se puede hacer si el número de renglones de una matriz es igual al número de columnas de la otra matriz, es decir, una matriz es de dimensiones $r \times c$ y la otra debe ser $c \times q$.

```
B %*% t(B)

[,1] [,2] [,3]
[1,] 17 22 27
[2,] 22 29 36
[3,] 27 36 45
```

Podemos *combinar* matrices si tienen el mismo número de renglones, o el mismo número de columnas para crear una matriz más grande:

Operaciones con matrices III

Para combinar por renglones, usamos la función rbind

factores como matrices

En realidad, los objetos que llamamos factores, en realidad son matrices.

Arreglos I

Arreglos

Los Arreglos son una extensión de las matrices, en donde se pueden agregar más dimensiones (dim) de longitud 3 o más.

Por ejemplo:

```
x <-1:30

\dim(x) <- c(5,2,3) # es como un 'cubo'

\dim \max(x) <- list(color = colores, tipo = c("gordo", "flaco"), var = c("H", "M", "N"))
```

Los elementos se pueden accesar como en el caso de vectores.

Arreglos II

```
x[3,2,1]
[1] 8
x[,,1]
         # caras del arreglo
          tipo
color
           gordo flaco
  rojo
  amarillo
  negro
  azul
  blanco
x[2..3]
gordo flaco
        27
```

La convención en R para *llenar* un arreglo es la siguiente: el primer índice es el que se 'mueve' más rápido y el último es el que se 'mueve' más lento.

Un arreglo sigue siendo un vector, pero con más dimensiones. Acomodar las cosas en dimensiones puede ser útil para *organizar la información*.

Listas I

listas

Una *lista* es un objeto que sirve para contener otros objetos que pueden ser todos de diferentes tipos.

- Esta puede ser la estructura de datos más interesante para almacenar datos que se conocen como no-estructurados. El manejo de las listas puede ser un poco más difícil de entender, por la manera en que tenemos que accesar a sus elementos. Lo veremos a través de un ejemplo concreto
- Consideremos un crédito a una persona. El crédito tiene varias características importantes que se tienen que definir:
 - El tipo: puede ser hipotecario, tarjeta de crédito, personal, automotriz.
 - El monto del préstamo
 - La tasa de interés que tiene el crédito
 - Su plazo (en meses)
 - su fecha de contratación
 - datos demográficos de la persona que recibe el crédito (edad, sexo, estado civil).

Podemos definir una lista con todas estas características:

```
Credito <- list(tipo = "Hipotecario",
               plazo = 28,
               fecha = "01/04/20",
               tasa = 7.58.
               demograficos = c(35,1,0))
Credito
$tipo
[1] "Hipotecario"
$plazo
Γ17 28
$fecha
[1] "01/04/20"
$tasa
Γ1] 7.58
$demograficos
[1] 35 1 0
```

• A los elementos de la lista se puede accesar ya sea por posición o por nombre:

```
Credito[[3]] #tercer objeto en la lista

[1] "01/04/20"
Credito[3] # lista con un componente

$fecha
[1] "01/04/20"
Credito$fecha #componente con nombre fecha
[1] "01/04/20"
Credito[3:4] #se seleccionan varios elementos como vector

$fecha
[1] "01/04/20"
$tasa
[1] 7.58
```

Se nos olvidó agregar el monto:

```
Credito <- c(Credito, monto = 1.2) #se agrega el monto del crédito, en millones
Credito
$tipo
[1] "Hipotecario"
$plazo
Γ11 28
$fecha
[1] "01/04/20"
$tasa
[1] 7.58
$demograficos
[1] 35 1 0
$monto
[1] 1.2
```

Elimina el componente monto de la lista

```
Credito$monto <- NULL #0 Credito[["monto"]] <- NULL
Credito

$tipo
[1] "Hipotecario"

$plazo
[1] 28

$fecha
[1] "01/04/20"

$tasa
[1] 7.58

$demograficos
[1] 35 1 0</pre>
```

 La función unlist convierte una lista en un vector, pero se aplica coerción para que todos los objetos tengan el mismo tipo, y cuando un objeto tiene una dimensión mayor, agrega cada componente numerado secuencialmente.

```
unlist(Credito)
    tipo plazo fecha tasa demograficos1
"Hipotecario" "28" "01/04/20" "7.58" "35"
demograficos2 demograficos3
    "1" "0"
```

- Un dataframe es una lista hecha de vectores de la misma longitud, pero pueden ser de diferente tipo. Es la estructura más adecuada para guardar datos estructurados y lo más cercano a lo que se conoce como una base de datos.
- Un dataframe tiene atributos que las listas no tienen. La función data.frame genera un dataframe. Se puede usar la función cbind o rbind como si los datos fueran una matriz, pero regresa un dataframe:

```
z <- data.frame(inst = factor(c("Cete", "Cete", "MO", "M1", "M1")),</pre>
               precio = c(9.91, 9.93, 9.988, 9.87, 9.67),
               ven = rep("01/10/04".5))
 7.
 inst precio
                 ven
1 Cete 9.910 01/10/04
2 Cete 9.930 01/10/04
   MO 9.988 01/10/04
   M1 9.870 01/10/04
   M1 9.670 01/10/04
(z2 \leftarrow cbind(z,z))
 inst precio
              ven inst precio
1 Cete 9.910 01/10/04 Cete 9.910 01/10/04
2 Cete 9.930 01/10/04 Cete 9.930 01/10/04
   MO 9.988 01/10/04 MO 9.988 01/10/04
   M1 9.870 01/10/04 M1 9.870 01/10/04
   M1 9.670 01/10/04 M1 9.670 01/10/04
```

33/39

```
attributes(z)

$names
[1] "inst" "precio" "ven"

$class
[1] "data.frame"

$row.names
[1] 1 2 3 4 5
```

• Los dataframes pueden ser indexados como matrices o como listas.

```
z[2] #es un dataframe

precio
1 9.910
2 9.930
3 9.988
4 9.870
5 9.670
z[2]] #es un vector, que es el segundo elemento de la lista
[1] 9.910 9.930 9.988 9.870 9.670
z[z$inst == 'Cete',] # selecciona sólo los instrumentos que son Cetes.
inst precio ven
1 Cete 9.91 01/10/04
2 Cete 9.93 01/10/04
```

• Matrices y listas pueden ser anexadas a un dataframe:

```
y <- matrix(rnorm(10),nrow=5)
          [,1]
                   [,2]
     0.6435357 0.5651740
[2,] 2.2541716 -1.5693935
[3.] 3.3103538 -0.4537194
[4.] -0.4811477 0.4872859
[5,] 0.7983866 0.5044409
z <- data.frame(z,y)
z
 inst precio
1 Cete 9.910 01/10/04 0.6435357 0.5651740
2 Cete 9.930 01/10/04 2.2541716 -1.5693935
   MO 9.988 01/10/04 3.3103538 -0.4537194
   M1 9.870 01/10/04 -0.4811477 0.4872859
   M1 9.670 01/10/04 0.7983866 0.5044409
```

Qué es la indexación?

La indexación consiste en extraer partes de un objeto en R, típicamente de alguna de las estructuras de datos.

Para vectores, los vectores índices pueden ser de 5 tipos:

1 Una proposición lógica que se puede valuar como verdadera o falsa para cada elemento del vector:

```
y [,1] [,2]
[1,] 0.6435357 0.5651740
[2,] 2.264716 -1.6693935
[3,] 3.3103538 -0.4537194
[4,] -0.4811477 0.4872859
[5,] 0.7983866 0.5044409

y < 0
[1,1] [,2]
[1,] FALSE FALSE
[2,] FALSE TRUE
[3,] FALSE TRUE
[4,] TRUE FALSE
[5,] FALSE FALSE
[5,] FALSE FALSE
[5,] FALSE FALSE
[7] Y < 0]
[11] -0.4811477 -1.5693935 -0.4537194
```

Un vector de enteros positivos o un factor:

```
z[z$inst == "MO", ]

inst precio ven X1 X2
3 MO 9.988 01/10/04 3.310354 -0.4537194
```

Un vector de enteros negativos: sirve para excluir términos:

```
y[-c(2,5,8)]
[1] 0.6435357 3.3103538 -0.4811477 0.5651740 -1.5693935 0.4872859 0.5044409
```

- Un vector de cadenas de caracteres: esto sólo aplica cuando el objeto tiene nombres. De otra forma, devuelve NA.
- La posición de índice es vacía. y[]. Se comporta como si se reemplazara el índice por 1:length(y).
- ullet Un arreglo puede ser indexado por una matriz: si el arreglo tiene k índices, la matriz índice debe ser de dimensiones $m \times k$ y cada renglón de la matriz es usado como un conjunto de índices especificando un elemento del arreglo.

Indexación III

Índices ceros no caen en ningún caso anterior: un índice 0 en un vector ya creado pasa nada y un índice 0 en un vector al que se le asigna un valor no lo acepta:

```
a <- 1:4
a[0]
integer(0)
a[0] <- 10
a
[1] 1 2 3 4
```

Ejercicio 3

R tiene algunos archivos de datos precargados para mostrar cómo se realizan algunos análisis de datos. En este caso, carguen el conjunto de datos que se llama state.x77 que contiene algunas estadísticas de cada estado de los EUA, para el año 1977:

head(state.x77) Population Income Illiteracy Life Exp Murder HS Grad Frost Alabama 3615 3624 69.05 15.1 41.3 20 50708 Alaska 365 6315 69.31 11.3 66.7 152 566432 2212 4530 1.8 70.55 7.8 58.1 15 113417 Arizona Arkansas 2110 3378 1.9 70.66 10.1 39.9 65 51945 21198 5114 71.71 10.3 62.6 California 20 156361 Colorado 2541 4884 0.7 72.06 6.8 63.9 166 103766

- On los datos anteriores, hacer lo siguiente:
 - Calculen la media de analfabetismo y de asesinatos de ese año.
 - Ordenar los valores de menor a mayor de acuerdo al número de asesinatos, usando la función sort
 - Hagan una gráfica que muestre los datos de manera útil.
 - Identifiquen los estados que tienen una tasa de asesinatos mayor al 12 %.
 - Grafica los datos para tasa de analfabetismo y número de asesinatos.
 - Obten el subconjunto de datos que empiezan con "M".